

مهندسی دادههای حجیم زمستان ۱۴۰۰ بهار ۱۴۰۱ مجتبی استواری ابوالفضل طاهری

تمرین ـ سری اول

به جز ۲ تمرین آخر، باقی تمرینات باید به شکل اسکریپتهای bash نوشته شوند. برای هر تمرین لطفا توضیح کامل بدهید که دستورات شما هر کدام چه کاری انجام میدهند.

مساله ۱. اسکریپتی بنویسید که به عنوان آرگومان ورودی آدرس یک دایرکتوری را بگیرد و در صورتی که دایرکتوری مساله ۱. اسکریپتی بنویسید که به عنوان آرگومان ورودی آدرس یک دایرکتوری را به کاربر نمایش داد و با کد ۱ از برنامه خارج شود. در صورتی که آدرس درست بود، طول اسم فایلهای این دایرکتوری را بدون پسوند در نظر بگیرد و ماکزیمم این اعداد را در خروجی چاپ کند.

مساله ۲. یک متغیر تعریف شده داریم به نام RANDOM که با هر بار صدا زده شدن یک عدد تصادفی بین ۰ و ۳۲۷۶۷ برمی گرداند.

الف) اسکریپتی بنویسید که راستی آزمایی این باشد که عددی که به این شکل تولید می شود از یک توزیع یکنواخت می آید.

ب) فرض کنید میخواهید عدد تصادفی در بازه n تا n تولید کنید. با استفاده از متغیر فوق تابعی بنویسید که عدد n ما عدد n را به عنوان ورودی بگیرد و یک عدد تصادفی برگرداند. راستی آزمایی را برای تابع خود نیز انجام دهید.

مساله ۳. درproc/cpuinfo/ اطلاعات مربوط به پردازندهی سیستم را میتوانید ببینید. با استفاده از آن اسکریپتی بنویسید که تعداد پردازندههای سیستم شما را نمایش دهد.

مساله ۴. اسکرییتی بنویسید که از آدرس

 $https://en.wikipedia.org/wiki/Bash \ (Unix \ shell)$

شروع كند و تمام صفحات تا عمق ۲ را پيش رفته و تعداد تكرار هر كلمه را حساب كند.



مساله ۵. یک ریپازیتوری گیت ایجاد کنید که برنچهای زیر را داشته باشد:

در هر برنچ، هزار کامیت میخواهیم داشته باشیم که پیام کامیت اام

added the \${i}th number

باشد و در آن کامیت صرفا یک فایل با اسم

 $\{i\}.txt$

موجود باشد که محتوای آن عدد iام یک دنباله ی فیبوناچی است که دو عدد اول دنباله از اسم برنچ گرفته شده است. مثلا در برنچ fib fib fib fib

added the 1st number:

1.txt: 4

added the 2nd number:

2.txt: 5

added the 3rd number:

3.txt: 9

added the 4th number:

4.txt: 14

در مثال بالا ، توجه کنید که $\{i\}$ برای اعداد یک ، دو و سه حالت استثنایی دارد.

مساله ۶. در مورد consistency و availability در کلاس صحبت کردیم و با توجه به قضیه CAP نمی توان همزمان هر دوی این موارد را به طور کامل داشت. در هر یک از نمونه های زیر توضیح دهید که انتخاب کدامیک از این موارد در شرایط اضطراری مناسب تر است:

- اگر با نرم فزار اسپاتیفای آشنا باشید، لیستهایی پیشنهادی به هر کاربر ارائه میکند. برای ساخته شدن این لیستها نیاز به داشتن اطلاعات کاربران در زمانهای گذاشته وجود دارد و این لیستها براساس این اطلاعات ساخته می شود. با توجه به حجم بالای این اطلاعات از سیستمهای توزیع شده برای نگهداری و محاسبات روی آنها استفاده می شود. در این حالت اولویت شما چیست؟
- در شتاب دهنده ی سرن، حجم اطلاعات تولید شده بسیار بالاست و برای نگهداری اطلاعات از سیستمهای توزیع شده استفاده می شود. این اطلاعات برای بررسی نظریه های فیزیکی کاربرد دارد. در این مورد برای بررسی این نظریه ها تصمیم شما چیست؟



مساله ۷. در مورد کش توزیع شده در کلاس صحبت کردیم و برای بحث scalability از رپلیکیشنهایی برای خواندن استفاده شده به همراه لیدر. حال فرض کنید که برای رپلیکیشن بخواهیم از همان نودهایی که به عنوان سرورهای اصلی هستند و برای توزیع کش از آنها استفاده کردهایم استفاده کنیم. این کار چطور ممکن است، چه مزایایی دارد و چه مشکلاتی ممکن است پیش آورد؟